

第 1 組期末專案報告

Final Project: JetBot Autonomous Road Following and Traffic Sign Recognition



期末專案賽道

組別：第 1 組

班級、姓名與學號：

電資二 113820020 林政德

電資二 113820033 謝奕宏

電資二 112820034 呂伊茹

日期：2026.06.24

一、實驗內容

1.1 此次實驗需要做什麼？

本期末專案將本學期完成的兩個 JetBot 子任務整合成一套可實際部署於 NVIDIA Jetson Nano 自走車上的自主駕駛系統。最終部署版本位於：

`.deploy_jetbot/Final_team_1.ipynb`

此筆記本是實際放入 JetBot 的主控程式，也是本報告的主要講述對象。報告後續會以 Notebook 中的 **單元一**、**單元二**、**單元三** 為主線，說明我們如何從單功能測試逐步走到最終整合展示。系統的核心目標如下：

1. **自主道路跟隨**：使用 ResNet-18 迴歸模型預測畫面中的道路目標點 (X, Y)，再轉換為左右馬達差速控制，使 JetBot 能沿著賽道穩定行駛。
2. **交通路牌辨識與行為控制**：使用 YOLOv4-tiny TensorRT 模型辨識 stop、rail、pedestrian、blocked 四類號誌，並依照路牌優先權執行停車、減速或安全停止。
3. **雙模型整合部署**：在 Jetson Nano 4GB 記憶體與 GPU 資源有限的條件下，透過 TensorRT、分頻推論、單相機串流與 CUDA context 管理，使雙模型能在同一台 JetBot 上穩定運作。
4. **實車可調校性與安全性**：將主控程式拆成三個單元，分別測試道路跟隨、路牌辨識與最終整合版本；每個單元皆設計安全停止 Cell，以避免相機資源佔用、GPU 記憶體殘留與馬達失控。

本專案不是單純的離線模型測試，而是完整的邊緣 AI 系統整合。模型必須在 JetBot 上即時推論，推論結果必須立即轉換為馬達輸出，且車輛在遇到不同交通號誌時必須做出符合規則的動作。

1.2 最終部署內容

實際部署至 JetBot 的資料夾為 `.deploy_jetbot`，主要內容可分為五類：

- **主控程式**：`Final_team_1.ipynb`。實車執行的 Jupyter Notebook，包含 TensorRT 轉換、三個測試單元與最終整合控制。
- **道路跟隨模型**：`road_following_model/` 內含 PyTorch 權重、ONNX、TensorRT engine 與 TRTModule 載入檔，供 ResNet-18 道路座標迴歸使用。
- **交通路牌模型**：`yolo/` 內含 `yolov4-tiny-416.cfg`、`yolov4-tiny-416.weights`、`yolov4-tiny-416.trt` 與 `obj.names`。
- **YOLO TensorRT 工具庫**：`trt_yolov4-tiny-master/`，提供 YOLO 推論封裝、plugin、轉換腳本與 `utils/yolo.py`。
- **部署文件**：`START_HERE.txt`、`使用說明.md`、`deploy_structure.md`，說明 JetBot 端放置位置、模型編譯流程與安全停機方式。

其中真正的最終執行入口為 `Final_team_1.ipynb`。其餘歷史 notebook 與工具檔保留於部署資料夾中，主要用於轉換、測試或追溯；正式展示時以 `Final_team_1.ipynb` 的單元三為準。因此本報告不是以檔案清單為中心，而是以這份主控 Notebook 的三段式設計為中心。

1.3 系統架構概觀

本系統由「道路跟隨模型」、「路牌偵測模型」與「行為控制狀態機」三部分組成。整體流程如下：



圖 1：JetBot 最終系統架構

在最終整合單元中，Camera 解析度設定為 224x224、FPS 設定為 10。道路模型每一幀皆執行；YOLO 則使用 YOLO_INTERVAL = 3，每 3 幀才將影像放大至 416x416 執行一次路牌推論。此設計可讓道路跟隨保持高頻率控制，同時避免 YOLO 偵測佔用過多 GPU 時間。

1.4 核心技術對照表

本整合專案部署時採用的關鍵技術如下：

- **邊緣運算平台**：NVIDIA Jetson Nano / JetBot，負責 CSI 相機輸入、GPU 推論與馬達控制。
- **道路跟隨模型**：ResNet-18 Coordinate Regression，輸出道路目標點 (X, Y)。
- **路牌偵測模型**：YOLOv4-tiny Object Detection，偵測 stop、rail、pedestrian、blocked 四種號誌。
- **推論加速**：TensorRT、FP16、ONNX、TRTModule，用於降低延遲與 VRAM 使用量。
- **雙模型分頻**：道路模型每幀推論，YOLO 每 3 幀推論，使車輛保持速度。
- **控制與安全**：PD Controller、彎道自適應降速、馬達死區補償、try-except safety latch 與 safe-stop cell。

二、實驗過程及結果

2.1 預期實驗的結果

本次實驗預期 JetBot 能在實體賽道上完成自主道路跟隨，並能辨識 stop、rail、pedestrian、blocked 四類交通號誌。整合後的車輛應能在不明顯蛇行、不頻繁誤觸路牌的情況下通過完整賽道，並在遇到交通事件時做出停車、減速或安全停止。

2.2 實際上的結果

2.2.1 道路跟隨模型訓練與評估

道路跟隨模型延續 Project 5 的成果，以 JetBot CSI 相機拍攝的道路影像作為輸入，並以人工標記的目標座標 (X, Y) 作為迴歸標籤。本次巡路資料收集約 **800 張道路影像**，用來涵蓋直線、轉彎、光線變化與賽道邊界等情境。模型任務不是分類，而是直接預測車輛下一步應朝向的位置。

訓練流程如下：

1. 使用 JetBot 在跑道上收集約 **800 張**道路影像。
2. 透過 Gamepad 標記每張影像中的目標點。
3. 將影像與座標整理成 xy_{X}_{Y}_{uuid}.jpg 格式。
4. 使用 ResNet-18 作為骨幹網路，將最後一層改為 2 維輸出。
5. 使用 MSE Loss 訓練模型，使輸出座標接近人工標記座標。
6. 將最佳權重儲存為 best_steering_model_xy.pth。

道路模型的輸入尺寸為 224x224，輸出為正規化後的 (X, Y)。訓練完成後，在測試集上的預測點與人工標記點高度重合，平均像素誤差為 **12.702 px**。下圖展示最佳與最差預測案例：

最佳預測案例	最差預測案例
模型預測最精準的 4 張樣本 (綠=真實, 紅=預測) Best #1: xy_094_110_d4d6d1dc-6a21-11f1-908d-7404f1c2a475.jpg 誤差: 1.38 像素 Best #2: xy_009_164_9486d826-6a22-11f1-908d-7404f1c2a475.jpg 誤差: 1.72 像素 Best #3: xy_145_156_1649c1d4-6a21-11f1-908d-7404f1c2a475.jpg 誤差: 1.73 像素 Best #4: xy_074_126_9a61cbae-6a22-11f1-908d-7404f1c2a475.jpg 誤差: 2.32 像素 ● 真實中心 ● 預測點	模型誤差最大的 4 張樣本 (綠=真實, 紅=預測) Worst #1: xy_188_111_e7e13efe-6a23-11f1-908d-7404f1c2a475.jpg Worst #2: xy_152_145_7a08921e-6a23-11f1-908d-7404f1c2a475.jpg 誤差: 31.65 像素 Worst #3: xy_209_174_8b0fe502-6a26-11f1-908d-7404f1c2a475.jpg Worst #4: xy_083_121_c0b01486-6a23-11f1-908d-7404f1c2a475.jpg 誤差: 27.61 像素 ● 真實中心 ● 預測點
圖 2a：最佳預測案例	圖 2b：最差預測案例




圖 3：道路跟隨模型像素誤差分布
從評估結果可觀察到，多數測試影像的誤差集中在低像素區間，表示模型已能穩定掌握道路中心方向。少數較大誤差通常出現在急彎、光線變化或道路邊界不清楚的影像，這也是後續在控制器加入彎道自適應降速的原因之一。

實體賽道與行駛方向	道路模型預測視覺化
圖 4a：期末實體賽道與行駛方向	圖 4b：道路模型預測點與標記點比對

2.2.2 道路 TensorRT 轉換

JetBot 的 Jetson Nano 雖具備 GPU，但資源遠低於桌面訓練環境。若直接使用 PyTorch 模型執行推論，延遲會影響控制穩定性，使車輛在彎道反應過慢。因此最終版本在 JetBot 端將道路模型轉換為 TensorRT。

Final_team_1.ipynb 的 Cell 2 負責道路模型轉換，流程如下：




圖 5：道路模型 TensorRT 轉換流程

轉換時優先使用 FP16 半精度編譯：

```

/usr/src/tensorrt/bin/trtexec \
--onnx=road_following_model/best_steering_model_xy.onnx \
--saveEngine=road_following_model/best_steering_model_xy.engine \
--fp16 \
--workspace=1024
  
```

若 FP16 編譯失敗，程式會自動降級為 FP32，確保模型仍能在 JetBot 上完成轉換。轉換完成後，程式會重新載入 PyTorch 模型與 TensorRT 模型，使用相同輸入做一致性檢查。最終部署版本實測 $\text{max_diff} = 0.000520$ ，小於 0.01 的容許誤差，因此可確認 TensorRT 轉換沒有造成明顯精度失真。

此處特別使用暫存檔與 os.replace() 原子替換，避免在轉換失敗時留下不完整的 best_steering_model_xy_trt.pth，提升部署可靠性。

2.2.3 路牌辨識模型與類別定義

交通路牌辨識延續 Project 6 的 YOLOv4-tiny 訓練成果。本次 YOLOv4-tiny 沒有重訓，而是沿用前次已完成訓練與驗證的權重，再將其部署為 TensorRT 引擎：

```
.deploy_jetbot/yolo/yolov4-tiny-416.trt
```

路牌類別檔 obj.names 定義如下：

```

stop
rail
pedestrian
blocked
  
```

因此程式中的 class id 對應為：

Class ID	類別名稱	JetBot 動作
0	stop	原地停止 2 秒，之後繼續道路跟隨

Class ID	類別名稱	JetBot 動作
1	rail	原地停止 5 秒，之後繼續道路跟隨
2	pedestrian	降速為 0.7 倍，維持 1 秒後恢復
3	blocked	最高優先權安全停止；偵測期間持續停止

YOLOv4-tiny 在驗證集上的 F1-Score 達到 **0.9330**，獨立測試集準確率達到 **97.06%**。下圖為訓練與評估結果：




圖 6：實際 JetBot 相機視角下的四類路牌偵測範例
圖 6 保留 YOLOv4-tiny 的 bounding box、類別名稱與 confidence，用來呈現 JetBot 實際部署時的相機視角與偵測條件。




圖 8：YOLOv4-tiny 測試集偵測結果總覽

YOLO 推論信心度門檻設定為 0.6。在實車環境中，除了信心度之外，系統也加入 bounding box 寬度門檻，避免遠處路牌、背景路牌或畫面邊緣誤判造成錯誤停車。

2.2.4 主控 Notebook 三個測試單元入口

最終部署的 Final_team_1.ipynb 分為三個單元。這樣的設計能在實車調校時逐步隔離問題，避免道路控制、YOLO 偵測與 CUDA 資源互相干擾。

三個測試單元分別為：

- **單元一 A1-A7：純道路跟隨測試。**只載入道路模型，調整 Speed、P Gain、D Gain、Bias。
- **單元二 B1-B7：純路牌辨識測試。**只載入 YOLO，測試 Stop、Rail、Pedestrian、Blocked 動作。
- **單元三 C1-C7：最終整合版本。**同時載入道路模型與 YOLO，進行完整賽道展示。

每個單元最後皆有安全停止 Cell。切換單元前必須先執行對應的 A7、B7 或 C7，確保：

- 解除 camera.observe() callback。
- 停止 JetBot 馬達。
- 停止 Camera。
- 同步 CUDA context。
- 釋放模型物件與 GPU cache。
- 必要時重置 Camera._instance，避免 GStreamer 相機被佔用。

這是實車部署中非常重要的工程細節。如果舊 callback 或相機 pipeline 沒有關閉，JetBot 可能出現 Resource busy、畫面全黑、GPU OOM 或馬達維持最後一次輸出的危險狀況。

2.3 Final_team_1.ipynb 三單元總覽

本專案最終版本不是把所有功能直接寫在同一段程式中，而是將實車部署流程明確拆成 **單元一**、**單元二**、**單元三**。這三個單元全部位於

於 `.deploy_jetbot/Final_team_1.ipynb`，也是實際放到 JetBot 上執行的主控流程。

這樣設計的原因很直接：JetBot 是實體車，不適合一開始就同時啟動道路模型、YOLO、CUDA context 與馬達控制。若直接跑最終版，一旦車輛壓線、路牌誤觸或相機被占用，就很難判斷問題來源。因此 Notebook 採用「先拆開測，再合併」的方式。

Final_team_1.ipynb 的三個主單元如下：

Notebook 單元	Cell 範圍	主要目的	通過標準
單元一：純道路跟隨測試	A1-A7	只測 ResNet-18 道路模型、PD 控制與馬達輸出	JetBot 能沿道路前進，直道不蛇行，彎道不明顯外拋
單元二：純交通路牌辨識測試	B1-B7	只測 YOLOv4-tiny 與四類路牌動作	Stop、Rail、Pedestrian、Blocked 皆能觸發正確行為
單元三：合併最終版	C1-C7	同時整合道路跟隨與路牌辨識	能完成賽道，並在行駛中處理交通號誌

三個單元之間不是彼此獨立的展示，而是一條逐步驗證鏈：單元一先證明車可以穩定走路，單元二再證明車看得懂路牌，單元三最後才把兩者合併成期末驗收版本。



圖 9：Final_team_1.ipynb 三單元驗證矩陣

因此本報告在說明三個單元時，不採用單純流水帳式的執行順序，而是針對每個單元依序說明：問題定位、輸入與處理流程、參數與控制策略、進入下一階段的判斷依據。

2.4 單元一：純道路跟隨測試

在 `Final_team_1.ipynb` 中，單元一對應 A1-A7。此單元只載入道路跟隨模型，不載入 YOLO，也不執行交通號誌狀態機。它的任務是先確認 JetBot 本身能不能穩定沿著道路行駛。

單元一的目標是排除 YOLO 與 PyCUDA 的干擾，只檢查道路模型與馬達控制。若車輛在此單元就無法穩定行駛，問題通常來自道路模型、相機畫面、PD 參數或馬達偏差，而不是路牌辨識。


單元一實際要回答的是：「只靠道路模型與 PD 控制，JetBot 是否能穩定跑完基本路線？」因此它的輸入、處理與輸出非常明確：

階段	單元一內容
輸入	JetBot Camera 224x224 影像
資料基礎	約 800 張 巡路訓練影像
模型	<code>road_following_model/best_steering_model_xy_trt.pth</code>
推論結果	ResNet-18 TensorRT 輸出道路目標點 (x, y)
控制方法	將 (x, y) 轉為轉向角，再用 PD 控制計算左右輪差速
輸出	<code>robot_r.left_motor.value</code> 與 <code>robot_r.right_motor.value</code>
通過條件	車輛能沿著白線賽道行駛，直道不明顯蛇行，彎道不持續外拋

這裡的重點不是「模型有跑起來」，而是模型輸出的座標必須能穩定轉成馬達控制。若模型預測點偶爾偏移，但 PD 控制仍能把車頭拉回道路中心，單元一就算達到可整合狀態；反之，如果車輛在沒有 YOLO 的情況下仍然壓線或蛇行，就不能進入單元三，因為整合後只會更難判斷問題來源。

單元一：純道路跟隨測試

只載入道路模型，確認目標點預測、PD 控制與馬達輸出



驗證重點：單元一先隔離路牌偵測，確認 JetBot 可以穩定沿道路行駛，作為後續整合基準。

圖 10：單元一道路跟隨控制流程

參數	最終設定
Camera 解析度	224x224
FPS	10
Speed 初始值	0.15
P Gain 初始值	0.10
D Gain 初始值	0.02
Bias 初始值	0.02
馬達死區補償	MIN_MOTOR_SPEED = 0.12

單元一實車調整後的 PID 與速度設定如下。這組參數的目標不是追求最高瞬間速度，而是在直道保持穩定、彎道不外拋，並讓單元三整合 YOLO 後仍有足夠控制餘裕。

調整項目	最終採用值	調整理由
Speed	0.15	在速度與穩定性之間取得平衡，保留 YOLO 推論造成的控制延遲餘裕
P Gain	0.10	提供足夠轉向修正力，讓車頭能快速回到道路中心
D Gain	0.02	抑制直道蛇行與出彎震盪，避免 P Gain 單獨作用造成過度修正
Bias	0.02	補償實車左右輪與車體微小偏差，使直道行駛時不需持續依靠 P 項修正
Curve Scale 下限	0.60	急彎時最低降至設定速度的 60%，降低壓線風險
馬達死區補償	0.12	避免低速差速時馬達輸出太小而不轉動

道路模型輸出 (x, y) 後，程式先將目標點轉成車體前方的轉向角：

```
y_forward = max((0.5 - y) / 2.0, 0.05)
```

```
angle = np.arctan2(x, y_forward)
```

接著以 PD 控制器計算轉向量：

```
now = time.monotonic()
```

```
dt = 0.1 if control_time_last_r is None else max(now - control_time_last_r, 0.02)
```

```
derivative = 0.0 if not pd_initialized_r else (angle - angle_last_r) * min(0.1 / dt, 2.0)
```

```
pid = angle * p_slider_r.value + derivative * d_slider_r.value
```

```
steering = pid + bias_slider_r.value
```

此處使用 time.monotonic()，是為了讓 D 項根據穩定的相對時間計算，不受系統時間校正影響。為了避免急彎時車速過快，程式再加入彎道自適應降速：

```
curve_scale = max(1.0 - abs(steering), 0.6)
```


```
base_speed = speed_slider_r.value * curve_scale
```

最後，為了解決 JetBot 低速時馬達不轉的死區問題，左右輪輸出會經過線性補償：

```
MIN_MOTOR_SPEED = 0.12
```

```
if left_motor > 0.01:
```

$\text{left_motor} = \text{MIN_MOTOR_SPEED} + (1.0 - \text{MIN_MOTOR_SPEED}) * \text{left_motor}$
if $\text{right_motor} > 0.01$:
 $\text{right_motor} = \text{MIN_MOTOR_SPEED} + (1.0 - \text{MIN_MOTOR_SPEED}) * \text{right_motor}$
單元一的驗證重點是：畫面中的綠色預測點是否落在合理道路中心、車輛是否能直道不蛇行、彎道是否能提前轉向、馬達左右偏差是否可透過 Bias 修正。



單元一確認完成後，代表 JetBot 已具備最基本的自主循跡能力，後續整合只需處理路牌事件如何覆蓋或調整道路控制。

2.5 單元二：純交通路牌辨識測試

在 Final_team_1.ipynb 中，單元二對應 B1-B7。此單元只載入 YOLOv4-tiny 路牌模型，不執行道路跟隨。測試時 JetBot 可以架高輪子或以直線慢速前進，目標是確認四種路牌事件都能正確觸發。
單元二的目標是單獨驗證 YOLOv4-tiny 的路牌辨識與行為狀態機。此單元不做道路跟隨，因此車輛只需要直線慢速前進或在架高狀態下測試路牌反應。這樣可以避免把「轉向不穩」誤判成「路牌控制錯誤」。
單元二實際要回答的是：「JetBot 看見路牌後，是否會觸發正確且不重複的動作？」因此這一單元不追求轉向表現，而是專門檢查偵測門檻、類別優先權與冷卻時間。

階段	單元二內容
輸入	JetBot Camera 416x416 影像
模型	yolo/yolov4-tiny-416.trt
推論結果	YOLO 輸出 bounding boxes、confidence、class id
觸發條件	Confidence 0.60 且 bounding box 寬度達門檻
狀態控制	blocked > stop > rail > pedestrian
輸出	停車、定時停止、減速或直線前進
通過條件	四種路牌都能觸發正確動作，且 Stop / Rail 不會連續重複觸發

這裡最重要的判斷不是「YOLO 有沒有框到東西」，而是「框到之後該不該讓車做動作」。實車畫面中可能出現遠方路牌、背景反光、邊緣殘影或同一張路牌連續出現在多幀中，因此單元二把 confidence、框寬、冷卻時間與優先權分開處理，避免把偵測結果直接等同於控制命令。

單元二：純路牌辨識測試

只載入 YOLO，驗證四類路牌、信心度門檻與交通行為




圖 12：單元二路牌辨識控制流程

參數	最終設定
Camera 解析度	416x416
FPS	10
YOLO 信心度	0.6
Base Speed 初始值	0.18
Alert Width 初始值	50 px
Stop 停止時間	2 秒
Rail 停止時間	5 秒
Stop 冷卻時間	12 秒
Rail 冷卻時間	15 秒
Pedestrian 減速倍率	0.7x，維持 1 秒

單元二的信心度與觸發門檻設定如下。正式測試時並不是只要 YOLO 看見路牌就立刻觸發，而是同時檢查信心度、框寬與冷卻時間，降低遠方路牌與背景誤判造成的錯誤動作。

- **Stop (Class 0)**：Confidence 0.60、框寬門檻 50 px，觸發後停止 2 秒。
- **Rail (Class 1)**：Confidence 0.60、框寬門檻 30 px，觸發後停止 5 秒。
- **Pedestrian (Class 2)**：Confidence 0.60、框寬門檻 50 px，觸發後以 0.7 倍速度減速 1 秒。
- **Blocked (Class 3)**：Confidence 0.60、框寬門檻 50 px，最高優先權，偵測

期間立即停止。

本專案的路牌類別順序以 `obj.names` 為準：

Class ID	類別	單元二測試動作
0	stop	偵測到近距離 stop 後停止 2 秒
1	rail	偵測到 rail 後停止 5 秒
2	pedestrian	速度降為 0.7 倍，通過後恢復
3	blocked	立即停止，優先權最高


路牌動作優先權如下：

`blocked > stop > rail > pedestrian`

防誤判是單元二最重要的設計。實車測試中，畫面可能同時看到遠方路牌、背景反光或邊緣殘影，如果只靠信心度會太容易誤觸。因此程式同時檢查信心度、框寬、冷卻時間與類別優先權：

```
width_thresholds = {
    0: slider_val,          # stop
    1: max(20, slider_val - 20), # rail
    2: slider_val,          # pedestrian
    3: slider_val            # blocked
}
```

Rail 路牌在畫面中通常比 Stop 小，所以門檻比其他類別低 20 px，但仍保留最低 20 px 限制。Stop 與 Rail 也加入冷卻時間，避免車輛剛起步還沒離開路牌，就再次被同一張卡片觸發。



單元二確認完成後，代表每個交通號誌都能被正確辨識，且能觸發預期動作。此時才進入單元三，將路牌狀態機與道路跟隨控制合併。

2.6 單元三：合併最終版

在 `Final_team_1.ipynb` 中，單元三對應 C1-C7。此單元是實際期末展示用的完整模式，會同時執行道路跟隨、YOLO 路牌偵測、狀態機判斷與馬達控制。單元三是期末展示使用的最終版本，也是 `Final_team_1.ipynb` 中真正用於驗收的主程式。它同時載入道路跟隨 `TensorRT` 模型與 `YOLOv4-tiny TensorRT` 模型，並透過分頻推論與狀態機把兩種任務整合成同一個 `callback`。

單元三在 `Notebook` 中的 `Cell` 分工如下。這個分工讓展示前可以逐步檢查模型、相機、控制介面、主迴圈與安全停止，而不是一次執行所有程式。

Cell	程式角色	實際功能	若此步驟失敗代表
C1	匯入完整套件	載入 Torch、OpenCV、JetBot、YOLO 工具庫與 plugin	部署路徑或 YOLO 工具庫位置錯誤
C2	載入雙模型	載入道路 TRTModule 與 YOLOv4-tiny TensorRT	模型檔缺失、TensorRT engine 不相容或 CUDA context 異常
C3	初始化相機與馬達	建立 224x224 Camera 與 Robot 物件	相機被舊單元占用或 GStreamer pipeline 未釋放
C4	建立控制介面	建立 Speed、P Gain、D Gain、Bias、Alert Width 滑桿與遙測欄位	參數無法即時調整，實車調校效率下降
C5	合併主迴圈	執行道路推論、YOLO 分頻、狀態機與馬達輸出	單元三核心邏輯錯誤
C6	啟動單元三	重置狀態變數，先做一次推論，再註冊 camera observer	首幀推論失敗或安全鎖啟動
C7	安全停止	解除 observer、停馬達、停相機、釋放模型與 GPU cache	切換單元或重跑時可能資源卡住


單元三實際要回答的是：「在 JetBot 的有限運算資源下，道路跟隨與路牌辨識能不能同時運作，並且不互相干擾？」這一單元不是把單元一、單元二程式碼相加而已，而是重新決定兩個模型的執行頻率、影像尺寸、CUDA context 管理與事件優先權。

整合問題	單元三採用的做法	原因
道路控制需要高頻率	道路模型每幀推論	車輛轉向延遲會直接造成壓線
YOLO 推論較重	YOLO 每 3 幀推論一次	降低 GPU 負載，避免道路控制卡頓
兩模型輸入尺寸不同	主相機 224x224，YOLO 時 resize 到 416x416	保留道路控制速度，同時符合 YOLO 輸入需求
PyCUDA 與 PyTorch 共用 GPU	YOLO 前後 <code>cuda_context_f.push() / pop()</code>	避免 CUDA context 衝突
停車期間仍可能出現 blocked	定時停車時仍週期性執行 YOLO	讓 blocked 能覆蓋 Stop / Rail，維持安全優先
同一張路牌可能重複觸發	Stop 冷卻 12 秒，Rail 冷卻 15 秒	起步後不會被同一路牌再次停車

因此單元三的驗收標準比前兩個單元更高：它不只要能沿線行駛，也要能在行駛過程中即時處理交通事件。最終最佳紀錄為 **壓線一次，時間 22.28 秒**，代表在速度、穩定性與事件處理之間已達到可展示的平衡。

單元三：合併最終版

道路跟隨與路牌辨識在同一個回呼函式內協作



整合重點：道路控制維持每幀反應；YOLO 以分頻推論降低負載；安全狀態可覆蓋一般行車控制。

圖 14：單元三最終整合控制流程

單元三的關鍵設計是：主相機使用 224x224，讓道路模型每一幀都可以直接推論；YOLO 則每 3 幀才執行一次，需要時才將影像放大到 416x416。

```
camera_f = Camera.instance(width=224, height=224, fps=10)
```

```
YOLO_INTERVAL = 3
```

```
run_yolo = (frame_count_f % YOLO_INTERVAL == 0)
```

```
if run_yolo:
```

```
    img_yolo = cv2.resize(img, (416, 416))
```

這樣做的原因是道路控制對頻率最敏感，若每幀都跑 YOLO，車輛會因 GPU 負載過高而轉向延遲；而路牌本身在畫面中的變化速度較慢，每 3 幀偵測一次仍足以反應。



圖 15：單元三雙模型分頻時序

YOLO TensorRT 使用 PyCUDA，道路模型使用 PyTorch / torch2trt。為避免兩者搶占 GPU context，單元三在 YOLO 推論前後明確管理 CUDA context：

```
cuda_context_f.push()
```

try:

```
boxes, confs, class = model_sign_final.detect(img_yolo, conf_th=0.6)
```

finally:

```
cuda_context_f.pop()
```

單元三也處理了「停車期間仍需看見 blocked」這個實車問題。若車輛正在 Stop 或 Rail 定時停車，系統仍會每 3 幀執行 YOLO，使 blocked 可以覆蓋原本狀態並立即停止。這讓安全優先權不會因定時停車而失效。

整合版最終達成的效果如下：

功能	單元三實際表現
道路跟隨	ResNet-18 每幀推論，車輛可沿賽道行駛
YOLO 偵測	每 3 幀推論一次，降低 GPU 負載
Stop	觸發後停止 2 秒，並套用 12 秒冷卻
Rail	觸發後停止 5 秒，並套用 15 秒冷卻
Pedestrian	觸發後 0.7 倍減速，維持 1 秒
Blocked	最高優先權，偵測期間立即停止
安全例外	callback 出錯時 robot.stop() 並設定 safety latch

單元三的重點不是單純把兩個模型同時載入，而是讓兩個模型以不同頻率協作：道路模型負責每幀控制，YOLO 負責較低頻率的環境事件判斷，狀態機再決定是否覆蓋道路控制。這也是本專案從單一模型作業進展到完整自走車系統的核心。

2.7 單元三內部流程與狀態機

2.7.1 每一幀的控制流程

最終版 `execute_final()` 每收到一張相機影像，會依照下列順序執行：

1. 讀取 224x224 相機影像。
2. 檢查是否處於 `safety latch` 或 `blocked stop` 狀態。
3. 判斷目前是否在 `Stop / Rail` 定時停車時間內。
4. 每 3 幀執行一次 YOLO；其他影格沿用上一輪偵測快取。
5. 根據 YOLO 結果做信心度、框寬、冷卻時間與優先權判定。
6. 若觸發 `Stop` 或 `Rail`，立即停車並提早 `return`。
7. 若觸發 `Pedestrian`，設定 1 秒減速 `latch`。
8. 若觸發 `Blocked`，立即停止並更新 `blocked` 時間戳。
9. 若可繼續行駛，執行道路模型推論。
10. 以 PD 控制、彎道降速與馬達死區補償計算左右輪輸出。
11. 更新畫面上的目標點、路牌框、動作文字與遙測資訊。

2.7.2 狀態機決策

狀態機以安全優先為原則，決策順序如下：

1. **Blocked Stop**：只要偵測到 `blocked` 且框寬達門檻，立即停止並覆蓋其他狀態。
2. **Timed Stop**：偵測到 `stop` 停止 2 秒；偵測到 `rail` 停止 5 秒。
3. **Pedestrian Slow**：偵測到 `pedestrian` 後，以 0.7 倍速度減速 1 秒。
4. **Lane Following**：沒有安全事件時，才執行道路跟隨與 PD 馬達控制。
5. **Safety Stop**：任何 `callback` 例外都會呼叫 `robot.stop()`，並設定 `safety latch`。

`Stop` 與 `Rail` 的定時停車期間仍會定期執行 YOLO，確保 `blocked` 可以立即升級為最高優先權的安全停止。

`Blocked` 在最終程式中使用 `last_blocked_time_f` 記錄最後一次看見 `blocked` 的時間，並在偵測期間與離開視野後短時間內持續停止。這讓車輛在實際展示時，只要道路封閉牌仍在前方，就會保持停止，不會因單幀漏檢立刻重新起步。



圖 16：單元三狀態優先權與觸發條件

2.7.3 雙模型分頻時序

道路跟隨與馬達控制需要高頻率更新，因此每幀都執行。路牌變化相對較慢，不需要每一幀都執行 YOLO。圖 15 顯示單元三的分頻方式：Frame 1、2 先沿用 YOLO 快取，Frame 3 執行一次 YOLO 偵測，Frame 4、5 再沿用快取，Frame 6 再次偵測。透過每 3 幀一次的分頻策略，系統能在保留路牌反應能力的同時，明顯降低 GPU 負載。

2.7.4 最終效能結果

最終整合版本在 JetBot 上能完成道路跟隨與路牌反應。相較於未優化的雙模型直接推論，最終版本透過 TensorRT 與分頻策略提升實車速度與穩定性。



圖 17：最終展示數據與部署參數總表

項目	結果
道路模型	ResNet-18 TensorRT，輸入 224x224
道路訓練資料	約 800 張巡路影像
路牌模型	YOLOv4-tiny TensorRT，輸入 416x416
相機主串流	224x224, 10 FPS
YOLO 分頻	每 3 幀推論一次
道路控制	每幀推論與馬達輸出
道路模型轉換誤差	max_diff = 0.000520
道路預測平均像素誤差	12.702 px
YOLO 驗證 F1-Score	0.9330
YOLO 獨立測試準確率	97.06%
整合推論速度	約 10 FPS 以上

實車測試中，JetBot 能在跑道上跟隨道路行駛，並對 Stop、Rail、Pedestrian、Blocked 做出對應動作。彎道自適應降速有效降低急彎壓線機率；冷卻時間與框寬門檻則降低了路牌重複觸發與遠距離誤觸問題。

2.8 遇到的問題與問題怎麼解決？

2.8.1 工程問題整理

本專案主要遇到的問題與解決方式如下：

- **相機資源被占用**：切換單元時舊的 Camera pipeline 或 observer 未釋放，會造成 Resource busy。解法是在每個單元設計 A7 / B7 / C7 安全停止 Cell。
- **PyTorch 推論延遲過高**：Jetson Nano 直接跑 PyTorch 反應太慢。解法是在 JetBot 端轉換成 TensorRT engine，並包裝為 TRTModule。
- **TensorRT engine 無法跨機器使用**：engine 與 JetPack、CUDA、TensorRT 版本高度相關。解法是在目標 JetBot 上重新編譯。
- **YOLO 與 PyTorch 同時使用 GPU 不穩**：PyCUDA 與 PyTorch 會競爭 CUDA context。解法是在 YOLO 推論前後明確 push() / pop()。
- **停車後起步暴衝**：停車期間若累積舊畫面的 PD 狀態，起步時會使用過期轉向資訊。解法是定時停車期間直接 return，並重置 PD 狀態。
- **遠處路牌提前觸發**：只看信心度不足以避免背景路牌誤判。解法是加入 bounding box 寬度門檻。
- **Stop / Rail 重複停車**：車輛起步後仍在同一路牌前方。解法是 Stop 設定 12 秒冷卻，Rail 設定 15 秒冷卻。
- **低速馬達不動與急彎壓線**：低速輸出不足或急彎速度過快。解法是使用 MIN_MOTOR_SPEED = 0.12 與彎道自適應降速。

2.8.2 實車調校策略

本專案在實車測試時採用逐步調校，而不是直接啟動最終整合版本。調校順序如下：

1. **先測單元一道路跟隨**
確認道路模型方向正確，車輛能沿賽道前進。此階段只調 Speed、P Gain、D Gain、Bias。
2. **再測單元二路牌辨識**
不讓車輛轉向，只測路牌偵測與對應動作。此階段調整 Alert Width、信心度與各類別行為。
3. **最後測單元三整合版**
同時啟動道路跟隨與 YOLO，觀察雙模型是否互相影響，並微調速度與路牌框寬。
4. **每次切換都執行安全停止 Cell**
這是避免 JetBot 相機與 GPU 資源卡住的必要流程。
5. **先低速再加速**
初次上車測試以 Speed = 0.10 ~ 0.15 為主，確認安全後再逐步提高。

此調校方式能快速定位問題來源。例如若車子壓線，優先看道路模型與 PD 控制；若路牌不觸發，優先看 YOLO 信心度與框寬；若整合後變慢，則檢查 YOLO 分頻與 CUDA context。

2.8.3 安全注意事項

JetBot 是實體車輛，軟體錯誤可能造成馬達持續輸出。因此本組在測試時採用

以下安全原則：

- 第一次執行任一控制單元時，先將車輪架空。
- 每次切換單元前，先執行安全停止 Cell。
- 若相機畫面全黑或 Camera stop 失敗，重啟 Jupyter kernel，不直接執行下一個單元。
- 若 JetBot 端系統、kernel 或供電異常，Notebook 內的安全鎖可能無法執行，因此實車旁需保留人工斷電能力。
- 調整 Speed 時小幅增加，不直接使用高速度。


2.8.4 硬體風險與測試紀錄

除了程式與模型問題之外，實車測試也受到硬體狀態影響。本組測試期間曾遇到 SD 卡損壞與 JetBot 相機模組故障，雖然這些不是演算法本身的錯誤，但會直接造成環境重建、相機畫面中斷與測試進度延遲。因此後續測試時，硬體預檢也被納入正式流程。

事件	影響	處理
SD 卡損壞	JetBot 系統與套件環境需要重建，模型與 notebook 需重新部署	保留部署資料夾備份，重要模型檔與設定檔不只放在 JetBot 本機
相機模組故障	無法取得即時影像，導致道路模型與 YOLO 都無法進行實車驗證	測試前先確認 Camera 畫面、解析度與 pipeline 狀態，再啟動馬達控制

實車硬體問題處理流程

硬體異常先停止測試，再恢復環境，最後回到低速單元測試。




實務原則：硬體異常不直接歸因於模型錯誤，先確認電源、儲存、相機與 JetBot pipeline，再回到單元測試定位問題。

圖 18：實車硬體問題處理流程

2.9 實際上的結果與成果展示

2.9.1 實驗展示畫面

下圖為期末專案賽道與道路模型預測視覺化結果：

實體賽道	道路預測視覺化
	
圖 19a：實車測試賽道	圖 19b：道路模型預測點

2.9.2 最終成果摘要

本專案最終完成以下成果：

1. 完成 JetBot 道路跟隨模型訓練與測試，模型能穩定預測道路中心目標點。
2. 完成道路模型 TensorRT 轉換，並在 JetBot 端通過 PyTorch / TensorRT 一致性檢查。
3. 完成 YOLOv4-tiny 四類交通路牌辨識，包含 stop、rail、pedestrian、blocked。
4. 完成雙模型整合控制，讓 JetBot 能一邊跟隨道路，一邊依照路牌做出停車或減速動作。
5. 完成防誤判機制，包含框寬過濾、冷卻時間、優先權狀態機與 pedestrian latch。
6. 完成安全停止機制，降低相機資源占用、GPU context 失敗與 callback 例外造成的風險。
7. 完成 JetBot 實車部署資料夾 .deploy_jetbot，可直接放入 JetBot 對應目錄執行。

2.9.3 最佳實車紀錄

期末最終版以 Final_team_1.ipynb 的單元三作為正式展示模式，最佳實車紀錄如下：

最佳紀錄為：壓線一次，時間 22.28 秒。影片紀錄將於後續補上。

項目	最佳紀錄
測試模式	單元三：道路跟隨 + 路牌辨識最終整合

項目	最佳紀錄
完成時間	22.28 秒
壓線次數	1 次
控制參數	Speed 0.15 、 P Gain 0.10 、 D Gain 0.02 、 Bias 0.02
YOLO 觸發設定	Confidence 0.60 、 Alert Width 50 px 、 YOLO 每 3 幀推論一次
影片紀錄	後續補上最佳紀錄影片

此紀錄代表整合版在速度與穩定性之間已達到可展示狀態。雖然仍有 1 次壓線，但車輛能在雙模型同時運作下完成賽道，並維持 Stop 、 Rail 、 Pedestrian 、 Blocked 的事件處理能力。

2.9.4 成果連結

成果展示影片：複雜路徑

<https://youtu.be/AqjCYs9JIPk>

成果展示影片：繞圓圈測試

<https://youtube.com/shorts/IWKTjqhHQUo>

道路跟隨訓練照片集（約 800 張，後續可補正式連結）

https://github.com/Andy87877/NTUT_Multimedia_Applications_Project5/tree/main/dataset_xy

專案 GitHub 原始碼

https://github.com/Andy87877/NTUT_Multimedia_Applications_Project5

2.9.5 與預期結果比較

- **道路跟隨**：預期能沿直道與彎道行駛；實際上可完成道路跟隨，急彎透過動態降速改善穩定性。
- **路牌辨識**：預期能辨識四類交通路牌；實際上 YOLOv4-tiny 可辨識四類路牌，並觸發對應行為。
- **Stop / Rail**：預期能定時停車後繼續；實際上 Stop 停 2 秒、Rail 停 5 秒，並加入冷卻時間避免重複觸發。
- **Pedestrian / Blocked**：預期能減速與安全停止；實際上 pedestrian 使用 0.7 倍速度減速，blocked 具有最高優先權。
- **雙模型速度與安全性**：預期整合後不明顯卡頓；實際上透過 TensorRT 與 YOLO 分頻維持約 10 FPS 以上，並加入 safe-stop 與資源釋放流程。

三、本次實驗過程說明與解決方法（為上述「實驗過程及結果」的摘要、總結）

3.1 實驗過程

本期末專案完成了一套可實際部署於 JetBot 的自主道路跟隨與交通路牌辨識整合系統。相較於單一模型示範，本專案更接近真實邊緣 AI 系統，因為它同時處理了模型推論、相機串流、GPU 資源、馬達控制、狀態機決策與實車安全等問題。

在模型層面，道路跟隨使用 ResNet-18 迴歸模型，能將相機影像轉換為車輛前進目標點；路牌辨識使用 YOLOv4-tiny，能偵測四種交通號誌。在部署層面，兩個模型皆透過 TensorRT 加速，以降低 Jetson Nano 上的推論延遲。在控制層面，系統使用 PD 控制、彎道自適應降速與馬達死區補償，使 JetBot 行駛更平順。在安全層面，系統加入 safe-stop、callback 例外捕捉、CUDA context push/pop 與冷卻時間，提升實車展示的可靠性。

3.2 解決方法

最終版本的重點不只是「模型能辨識」，而是「模型能在車上穩定控制實體行為」。透過分單元測試與最終整合，本組成功將 Project 5 道路跟隨與 Project 6 路牌辨識合併成可運作的 JetBot 期末專案。

四、分工

本專案由三位組員共同完成，包含資料收集、模型訓練、JetBot 實車測試、整合程式開發、部署與報告整理。分工如下：

- 呂伊茹（112820034，33%）：道路跟隨資料收集與標記、賽道架設、實車測試、PD 參數與馬達偏差調整、小組報告內容整理與校對。
- 林政德（113820020，33%）：交通路牌資料整理、道路模型訓練協助、YOLO 辨識測試、實車路牌動作測試、控制參數調校與結果紀錄。
- 謝奕宏（113820033，34%）：雙模型整合程式開發、TensorRT 轉換流程、CUDA context 與 YOLO 推論整合、部署資料夾維護、成果影片整理與 GitHub 管理。